

0	5	7	0	5	5
0	1	0	0	1	5

1- Leite:  $2/10 = 0,2$  Manteiga:  $5/10 = 0,5$   
 Café:  $3/10 = 0,3$  Arroz:  $2/10 = 0,2$   
 Cebola:  $2/10 = 0,2$  Feijão:  $2/10 = 0,2$   
 Pão:  $5/10 = 0,5$

2ª etapa: 1:

Café:  $0,3$   
 Pão:  $0,5$   
 Manteiga:  $0,5$

2:

Café + Pão:  $3/10 = 0,3$   
 Café + Manteiga:  $3/10 = 0,3$   
 Pão + Manteiga:  $4/10 = 0,4$

3ª etapa: 1:

confiança  $\geq 0,8$

- Café + pão:  $3/3 = 1$  ✓
- Pão + café:  $3/5 = 0,6$  ✗
- Café + manteiga:  $3/3 = 1$  ✓
- Manteiga + café:  $3/5 = 0,6$  ✗
- Pão + manteiga:  $4/5 = 0,8$  ✓
- Manteiga + pão:  $4/5 = 0,8$  ✓

2: Café + pão + manteiga:  $0,3$

confiança  $\geq 0,8$

- Café e pão + manteiga:  $3/3 = 1$  ✓
- Café e manteiga + pão:  $3/3 = 1$  ✓
- Pão e manteiga + café:  $3/4 = 0,75$  ✗
- Manteiga + café e pão:  $3/5 = 0,6$  ✗
- Pão + café e manteiga:  $3/5 = 0,6$  ✗
- Café + pão e manteiga:  $3/3 = 1$  ✓

D	S	T	Q	Q	S	S
D	L	M	M	J	V	S

- |                        |                             |
|------------------------|-----------------------------|
| - café → pão : 1       | - café e pão + manteiga : 1 |
| - café → manteiga : 1  | - café e manteiga + pão : 1 |
| - pão + manteiga : 0,8 | - café + pão e manteiga : 1 |
| - manteiga + pão : 0,8 |                             |

lift:  $\frac{\text{confidence}(A \rightarrow B)}{\text{support}(B)}$

$$\frac{1}{0,5} = 2$$

$$\frac{1}{0,5} = 2$$

$$\frac{1}{0,5} = 2$$

$$\frac{1}{0,5} = 2$$

$$\frac{0,8}{0,5} = 1,6$$

$$\frac{1}{0,4} = 2,5$$

$$\frac{0,8}{0,5} = 1,6$$

2-

2 e 3 -

[https://colab.research.google.com/drive/1KnD7CvRE5eNsuqLexo92RXm6qw\\_DZQO?usp=sharing](https://colab.research.google.com/drive/1KnD7CvRE5eNsuqLexo92RXm6qw_DZQO?usp=sharing)

4 -

<https://colab.research.google.com/drive/1aarKD4BmOEHuGvgvMIJl68fYi25yH31d?usp=sharing>

5 - A biblioteca mlxtend é uma ferramenta em Python usada para mineração de padrões frequentes e geração de regras de associação. Utiliza o algoritmo Apriori para identificar itemsets frequentes com base em um suporte mínimo definido pelo usuário. Após isso, a função `association_rules` cria regras de associação no formato  $A \rightarrow B$ , avaliando-as por métricas como suporte (a proporção de transações contendo o itemset), confiança (a probabilidade do consequente ocorrer dado que o antecedente ocorre), lift (medindo a independência entre antecedente e consequente) e leverage (diferença entre a probabilidade conjunta e a probabilidade independente dos itens). A implementação típica envolve primeiro encontrar os itemsets frequentes usando apriori e, em seguida, gerar as regras de associação utilizando `association_rules`, ajustando métricas conforme necessário.

6- O artigo "A Comprehensive Review of Visualization Methods for Association Rule Mining," de I. Fister Jr. et al., faz uma revisão detalhada sobre as técnicas de visualização usadas para facilitar a compreensão das regras de associação em grandes bancos de dados. Os autores seguiram uma abordagem rigorosa de revisão de literatura, com o objetivo de identificar e entender as metodologias mais comuns na visualização de regras de associação, além de explorar as aplicações práticas dessas técnicas.

A pesquisa foi realizada nas bases Google Scholar, ACM Digital Library e IEEE Xplore, com foco em encontrar artigos sobre ARM (Association Rule Mining) e visualização. Ao todo, foram identificados 16.320 artigos, mas, após uma triagem rigorosa, apenas 25 estudos foram incluídos na revisão.

Os autores estruturaram a pesquisa em torno de várias perguntas importantes, como: quais são os métodos existentes para visualizar ARM? Quais desafios ainda precisam ser enfrentados? Quais ferramentas e pacotes de software estão disponíveis? E quais são as perspectivas futuras para esse campo? Os resultados mostram que a visualização desempenha um papel fundamental na análise de regras de associação, ajudando a interpretar padrões e relações nos dados de maneira mais intuitiva.

O artigo também revisa a evolução das técnicas de visualização, trazendo exemplos de métodos tradicionais e mostrando como algumas ferramentas, como o pacote `arulesViz`, podem ser usadas para criar visualizações práticas e eficientes. Embora o campo tenha avançado, os autores destacam que ainda há muitos desafios pela frente. Eles sugerem que as pesquisas futuras devem se concentrar em desenvolver métodos de visualização que sejam mais fáceis de entender e acessíveis para todos os usuários.